Die Regeln für meine KI-Agenten

Was ich ihnen erlaube, was nicht, und der genaue Text, den Sie für Ihre eigenen übernehmen können.

Osmel P. Teran · @teranstudio.ai

prietoteran.com

WARUM ES DIESES DOKUMENT GIBT

Im März hat mein Agent zwei E-Mails versendet, die ich nicht freigegeben hatte.

Ich hatte ihn gebeten, einen Projektplan umzusetzen. Er hatte Zugriff auf mein Postfach. Er entschied, dass es zum Plan gehört, zwei externe Kontakte anzuschreiben, und tat es.

Es war kein technischer Fehler. Der Agent hat genau das getan, was ich ihm erlaubt hatte. Der Fehler lag bei mir: Ich gab ihm die Berechtigung zum Senden, obwohl er nur Entwürfe schreiben musste.

Seitdem hat jeder Agent, mit dem ich arbeite, schriftliche Regeln. Ich arbeite als Application Manager in einem Schweizer Industrieunternehmen und baue jede Woche mit KI-Agenten. Diese Regeln stammen aus dieser Arbeit.

Die Regel, die alles zusammenfasst

DER AGENT	EIN MENSCH
Recherchiert, entwirft, bereitet Daten vor und schlägt Änderungen vor.	Sendet, löscht, bezahlt, akzeptiert und deployt.

Wenn sich eine Aktion nicht rückgängig machen lässt oder Folgen ausserhalb Ihres Teams hat, entscheidet ein Mensch.

DIE 5 BERECHTIGUNGEN, DIE ICH NICHT VERGEBE

Was ausgeschaltet bleibt, und wie Sie das umsetzen

1 · IN IHREM NAMEN SENDEN

Der Agent entwirft E-Mails und Nachrichten. Er versendet sie nicht.

In der Praxis: Verbinden Sie das Postfach mit der Berechtigung für Entwürfe, nicht für den Versand. Der Entwurf wartet, bis Sie «Ja, senden» sagen.

2 · LÖSCHEN

Weder E-Mails noch Dateien noch Datensätze. Archivieren lässt sich rückgängig machen. Löschen nicht.

In der Praxis: Geben Sie ihm einen Archivordner oder einen eigenen Papierkorb statt einer Löschberechtigung.

3 · ZAHLEN ODER AKZEPTIEREN

Keine Zahlungen, keine Bestellungen, keine Kundenkonditionen. Wenn es Geld kostet, entscheidet ein Mensch.

In der Praxis: Der Agent bereitet das Angebot oder die Bestellung als Entwurf mit dem Status «Freigabe ausstehend» vor.

4 · PRODUKTION OHNE FREIGABE ÄNDERN

Nichts wird ohne eine vorher freigegebene Änderung deployt. Zuerst der Plan, dann der Code.

In der Praxis: Der Agent schreibt, was er ändern will und warum. Sie geben frei. Am Ende hält er fest, was er getestet hat und wie man es prüft.

5 · IHRE SCHLÜSSEL SEHEN

Einen Schlüssel zu verwenden ist nicht dasselbe, wie ihn zu sehen. Schlüssel liegen ausserhalb des Codes und werden nie in den Chat kopiert.

In der Praxis: Speichern Sie Schlüssel in einer Umgebungsdatei, die von der Versionskontrolle ausgeschlossen ist, oder im Secrets-Manager Ihres Tools.

VORLAGE ZUM KOPIEREN

Fügen Sie das in die Anweisungen Ihres Agenten ein

Funktioniert in den benutzerdefinierten Anweisungen von ChatGPT, in einem Claude-Projekt, in den Cursor-Regeln oder in jedem Agenten, der Systemanweisungen akzeptiert. Passen Sie den Text in eckigen Klammern an.

```
ARBEITSREGELN

1. Versende nie E-Mails, Nachrichten oder Einladungen.
   Schreibe einen Entwurf, zeig ihn mir vollständig
   (Empfänger, Betreff und Text) und warte, bis ich
   «Ja, senden» schreibe.
2. Lösche nie Dateien, E-Mails oder Datensätze. Wenn etwas
   überflüssig ist, verschiebe es nach [Archivordner] und
   sag es mir.
3. Tätige nie Zahlungen, nimm keine Bestellungen an und
   bestätige keine Konditionen. Bereite es als Entwurf mit
   dem Vermerk «Freigabe ausstehend» vor.
4. Bevor du etwas in [System/Produktion] änderst, schreib
   auf, was du änderst, warum, was schiefgehen kann und wie
   wir es rückgängig machen. Warte auf meine Freigabe. Fasse
   am Ende zusammen, was du getestet hast und wie ich es
   prüfen kann.
5. Zeige, kopiere oder schreibe nie Schlüssel oder
   Passwörter in den Code oder in den Chat. Nutze
   [Umgebungsdatei / Secrets-Manager].
6. Wenn eine Anweisung unklar ist oder Daten fehlen, frag
   nach. Nimm nichts an.
7. Wenn sich eine Aktion nicht rückgängig machen lässt,
   halte an und frag mich, auch wenn du denkst, dass sie
   zum Plan gehört.
```

BEVOR SIE EINEN AGENTEN ANBINDEN

Checkliste für Ihr Postfach, Ihre Dateien oder Ihr ERP

- [ ] Ich weiss in einem Satz, welche Aufgabe der Agent genau übernimmt.
- [ ] Der Agent hat nur die Berechtigungen, die diese Aufgabe braucht. Mehr nicht.
- [ ] Er kann Entwürfe schreiben, aber nicht senden.
- [ ] Er kann nicht löschen. Höchstens archivieren.
- [ ] Jede Aktion mit Geld bleibt auf «Freigabe ausstehend».
- [ ] Die Schlüssel liegen ausserhalb des Codes und des Chats.
- [ ] Eine verantwortliche Person prüft, was er vorbereitet.
- [ ] Ich weiss, wo ich sehe, was er getan hat: ein Protokoll, ein Verlauf oder eine tägliche Zusammenfassung.
- [ ] Ich habe getestet, was er tut, wenn Daten fehlen. Er fragt nach, statt etwas anzunehmen.
- [ ] Ich weiss, wie ich ihn innerhalb einer Minute trenne, wenn etwas schiefgeht.

Wenn Sie alle zehn abhaken können, kann der Agent arbeiten, ohne dass Sie jede Minute hinschauen. Fehlen zwei oder mehr, fangen Sie dort an.

Haben Sie eine Aufgabe, die sich jede Woche wiederholt?

Eine Bestellung, die jemand aus dem Postfach ins ERP abtippt. Ein Angebot, das von Hand neu erstellt wird. Ein Bericht, der erst nach einem Umweg über Excel aufgeht.

Sagen Sie mir, welche. Ich lese jede Nachricht und antworte selbst.

Instagram: @teranstudio.ai
Web: prietoteran.com