Las reglas de mis agentes de IA

Lo que les permito hacer, lo que no, y el texto exacto que puedes copiar para los tuyos.

Osmel P. Teran · @teranstudio.ai

prietoteran.com

POR QUÉ EXISTE ESTE DOCUMENTO

En marzo, mi agente envió dos emails que yo no aprobé.

Le había pedido que ejecutara un plan de proyecto. Tenía acceso a mi correo. Decidió que escribir a dos contactos externos era parte del plan, y lo hizo.

No fue un fallo técnico. El agente hizo exactamente lo que le permití hacer. El error fue mío: le di permiso para enviar, cuando solo necesitaba permiso para redactar.

Desde entonces, cada agente con el que trabajo tiene reglas escritas. Trabajo como Application Manager en una empresa industrial suiza y construyo con agentes de IA cada semana. Estas reglas salen de ahí.

La regla que lo resume todo

EL AGENTE	UNA PERSONA
Investiga, redacta, prepara datos y propone cambios.	Envía, borra, paga, acepta y despliega.

Si una acción no se puede deshacer o tiene consecuencias fuera de tu equipo, la decide una persona.

LOS 5 PERMISOS QUE NO DOY

Qué queda apagado, y cómo hacerlo en la práctica

1 · ENVIAR EN TU NOMBRE

El agente redacta emails y mensajes. No los envía.

En la práctica: conecta el correo con permiso de borradores, no de envío. El borrador espera hasta que digas "sí, envíalo".

2 · BORRAR

Ni correos, ni archivos, ni registros. Archivar se deshace. Borrar, no.

En la práctica: dale una carpeta de archivo o una papelera propia en lugar de permiso de borrado.

3 · PAGAR O ACEPTAR

Ni pagos, ni pedidos, ni condiciones de un cliente. Si cuesta dinero, decide una persona.

En la práctica: el agente prepara la oferta o el pedido como borrador con estado "pendiente de aprobación".

4 · TOCAR PRODUCCIÓN SIN APROBACIÓN

Nada se despliega sin un cambio aprobado antes. Primero el plan, luego el código.

En la práctica: el agente escribe qué quiere cambiar y por qué. Tú apruebas. Al terminar, registra qué probó y cómo verificarlo.

5 · VER TUS CLAVES

Usar una clave no es lo mismo que verla. Las claves viven fuera del código y nunca se pegan en el chat.

En la práctica: guarda las claves en un archivo de entorno excluido del control de versiones, o en el gestor de secretos de tu herramienta.

PLANTILLA PARA COPIAR

Pega esto en las instrucciones de tu agente

Funciona en las instrucciones personalizadas de ChatGPT, en un proyecto de Claude, en las reglas de Cursor o en cualquier agente que acepte instrucciones de sistema. Cambia lo que está entre corchetes.

```
REGLAS DE TRABAJO

1. Nunca envíes emails, mensajes ni invitaciones. Redacta un
   borrador, enséñamelo completo (destinatario, asunto y texto)
   y espera a que escriba "sí, envíalo".
2. Nunca borres archivos, correos ni registros. Si algo sobra,
   muévelo a [carpeta de archivo] y dímelo.
3. Nunca hagas pagos, aceptes pedidos ni confirmes condiciones.
   Prepáralo como borrador marcado "pendiente de aprobación".
4. Antes de cambiar algo en [sistema/producción], escribe:
   qué vas a cambiar, por qué, qué puede fallar y cómo volver
   atrás. Espera mi aprobación. Al terminar, resume qué
   probaste y cómo puedo verificarlo.
5. Nunca muestres, copies ni escribas claves o contraseñas en
   el código ni en el chat. Usa [archivo de entorno / gestor].
6. Si una instrucción es ambigua o falta un dato, pregunta.
   No supongas.
7. Si una acción no se puede deshacer, para y pregúntame,
   aunque creas que forma parte del plan.
```

ANTES DE CONECTAR UN AGENTE

Checklist para tu correo, tus archivos o tu ERP

- [ ] Sé qué tarea exacta va a hacer el agente, en una frase.
- [ ] El agente tiene solo los permisos que esa tarea necesita. Nada más.
- [ ] Puede redactar, pero no enviar.
- [ ] No puede borrar. Como mucho, archivar.
- [ ] Cualquier acción con dinero queda pendiente de aprobación.
- [ ] Las claves están fuera del código y del chat.
- [ ] Hay una persona responsable que revisa lo que prepara.
- [ ] Sé dónde ver lo que ha hecho: un registro, un historial o un resumen diario.
- [ ] He probado qué hace cuando falta un dato. Pregunta en lugar de suponer.
- [ ] Sé cómo desconectarlo en un minuto si algo va mal.

Si marcas las diez, puedes dejar trabajar al agente sin mirarlo cada minuto. Si te faltan dos o más, empieza por ahí.

¿Tienes una tarea que se repite cada semana?

Un pedido que alguien copia del correo al ERP. Una oferta que se rehace a mano. Un informe que solo cuadra después de pasar por Excel.

Cuéntame cuál es. Leo cada mensaje y respondo yo.

Instagram: @teranstudio.ai
Web: prietoteran.com